TRƯỜNG ĐẠI HỌC SƯ PHẠM KỸ THUẬT VĨNH LONG

**KHOA CÔNG NGHỆ THÔNG TIN**

ĐỒ ÁN CƠ SỞ NGÀNH KHOA HỌC MÁY TÍNH

# CHỦ ĐỀ: ỨNG DỤNG EXPLAINABLE AI TRONG GIẢI THÍCH MÔ HÌNH HỌC SÂU

Giáo viên hướng dẫn : ThS Trần Hồ Đạt

Sinh viên thực hiện : Nguyễn Đức Trọng

MSSV: 22022012

Lớp : ĐH.KHMT 2022

Vĩnh Long, năm 2025

## NHẬN XÉT & ĐÁNH GIÁ ĐIỂM CỦA NGƯỜI HƯỚNG DẪN

Ý thức thực hiện:.....

.....

.....

.....

Nội dung thực hiên:.....

.....

.....

.....

Hình thức trình bày:.....

.....

.....

.....

Tổng hợp kết quả:.....

.....

.....

.....

□ Tổ chức báo cáo trước hội đồng

□ Tổ chức chấm thuyết minh

*Vĩnh Long,ngày……tháng……năm…….*

Người hướng dẫn

*(Ký và ghi rõ họ tên)*

# LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành đến Trường Đại học Sư Phạm Kỹ Thuật Vĩnh Long và Khoa Công Nghệ Thông Tin đã tạo điều kiện thuận lợi cho quá trình học tập và nghiên cứu của em trong đề tài "Ứng dụng Explainable AI trong giải thích mô hình học sâu".

Em xin đặc biệt tri ân Giáo viên hướng dẫn Trần Hồ Đạt, người đã tận tâm chỉ bảo, truyền đạt những kiến thức chuyên môn sâu rộng cũng như kinh nghiệm quý báu, giúp em vượt qua nhiều khó khăn trong quá trình nghiên cứu. Sự nhiệt huyết và tận tâm của cô đã tiếp thêm động lực để em hoàn thành báo cáo này với niềm tự hào và trách nhiệm.

Cuối cùng, em xin gửi lời cảm ơn sâu sắc đến gia đình và bạn bè, những người đã luôn ở bên cạnh, động viên và chia sẻ niềm vui cũng như khó khăn trong quá trình hoàn thành báo cáo. Em mong nhận được thêm những ý kiến đóng góp quý báu để công trình nghiên cứu ngày càng hoàn thiện hơn.

Trân trọng cảm ơn!

# MỤC LỤC

LỜI NÓI ĐẦU .....2
CHƯƠNG I: TỔNG QUAN ĐỀ TÀI .....3
1.1. Giới thiệu .....3
1.2 Vấn đề nghiên cứu .....3
1.3 Lịch sử và quan điểm lựa chọn đề tài .....3
1.4 Tóm tắt hoạt động nghiên cứu .....4
1.5 Mục tiêu nghiên cứu .....4
1.6 Phạm vi và đóng gói .....4
1.7 Ý nghĩa và ứng dụng .....4
CHƯƠNG II: CƠ SỞ LÝ THUYẾT .....6
2.1 Tổng quan về bệnh viêm phổi (Pneumonia) .....6
2.2 Tổng quan về Explainable AI (XAI) .....7
2.2.1 Giới thiệu Explainable AI (XAI) .....7
2.2.2 Vai trò và lợi ích của XAI .....8
2.2.3 Lịch sử phát triển của XAI .....9
2.3 EfficientNetB0 .....10
2.3.1 Lịch sử phát triển và mục tiêu của EfficientNetB0 .....10
2.3.2 Kiến trúc tổng quát của EfficientNetB0 .....11
2.3.3 Ưu điểm và nhược điểm của EfficientNetB0 .....15
CHƯƠNG III: CÁC PHƯƠNG PHÁP ĐỀ XUẤT .....17
3.1 Môi trường cài đặt .....17
3.2 Mô hình đề xuất .....18
3.3 Grad-Cam (Gradient-weighted Class Activation Mapping) .....19
3.3.1 Lịch sử ra đời và mục tiêu .....20

3.3.2 Nguyên lý hoạt động .....22
3.3.3 Ưu điểm và nhược điểm .....22
3.3.4 Ứng dụng trong ảnh y tế: .....22
3.4 LIME (Local Interpretable Model-agnostic Explanations) .....23
3.4.1 Lịch sử phát triển và mục tiêu .....23
3.4.2 Nguyên lý hoạt động .....24
3.4.3 Ưu điểm và nhược điểm của LIME .....25
3.4.4 Ứng dụng trong ảnh y tế .....25
CHƯƠNG IV : KẾT QUẢ THỰC NGHIỆM .....27
4.1 Mô tả tập dữ liệu: .....27
4.2 Môi trường cài đặt: .....27
4.3 Kết quả huấn luyện .....27
4.3.1 Biểu đồ Accuracy .....27
4.3.2 Biểu đồ Loss .....28
4.3.3 Thời gian huấn luyện .....28
4.4 Kết quả kiểm thử .....28
4.5 Đánh giá kết quả .....30
CHƯƠNG V : KẾT LUẬN VÀ HƯỚNG NGHIÊN CỨU .....31
5.1 Kết luận .....31
5.2 Thách thức .....31
5.3 Hướng phát triển .....31
TÀI LIỆU THAM KHẢO .....32

MỤC LỤC HÌNH ẢNH

Hình 2.1: Hình ảnh viêm phổi (Pneumonia) .....6

Hình 2.2: Giới thiệu chung về eXplainable AI .....8

Hình 2.3: EfficientNetB0 Architecture .....15

Hình 3.1: Môi trường Google Colab .....17

Hình 3.2: Mô hình đề xuất .....18

Hình 3.3: Ảnh ví dụ Grad-CAM .....20

Hình 3.4: Ảnh ví dụ LIME .....23

Hình 3.6: Bảng so sánh GRAD-CAM VÀ LIME .....26

.....27

Hình 4.3.1: Biểu đồ Accuracy của mô hình EfficientNetB0 .....27

Hình 4.3.2: Biểu đồ Loss của mô hình EfficientNetB0 .....28

Hình 4.4.1: Ảnh kết quả chẩn đoán sử dụng mô hình EfficientNetB0 .....29

Hình 4.4.2: Grad-CAM trên ảnh Pneumonia – vùng viêm phổi sáng rõ. .....29

Hình 4.4.3: LIME – superpixel quan trọng làm nổi bật rời rạc .....30

# LỜI NÓI ĐẦU

Trong những năm gần đây, trí tuệ nhân tạo (AI) và đặc biệt là học sâu (deep learning) đã đạt được nhiều thành tựu ấn tượng trong các lĩnh vực như thị giác máy tính, xử lý ngôn ngữ tự nhiên, y học, tài chính và nhiều ngành công nghiệp khác. Tuy nhiên, một trong những thách thức lớn nhất của các mô hình học sâu là tính "hộp đen" (black-box), khiến việc hiểu được lý do đằng sau các quyết định của mô hình trở nên khó khăn. Điều này đặt ra vấn đề quan trọng về tính minh bạch, độ tin cậy và khả năng giải thích của AI, đặc biệt trong các lĩnh vực yêu cầu cao về an toàn và đạo đức như y tế hay pháp lý.

Để giải quyết vấn đề này, Explainable AI (XAI) – Trí tuệ nhân tạo có khả năng giải thích – đã ra đời như một hướng nghiên cứu mới nhằm mở "hộp đen" của các mô hình học máy, giúp con người hiểu, tin tưởng và kiểm soát tốt hơn các hệ thống AI. Việc ứng dụng XAI không chỉ giúp cải thiện tính minh bạch mà còn hỗ trợ phát hiện lỗi, tăng khả năng chấp nhận của người dùng và tạo điều kiện cho việc kiểm chứng mô hình một cách khoa học.

Chuyên đề này tập trung vào việc ứng dụng Explainable AI để giải thích các mô hình học sâu, với trọng tâm là các phương pháp phổ biến như Grad-CAM, LIME và SHAP. Thông qua việc phân tích, đánh giá và thử nghiệm các kỹ thuật giải thích trên các mô hình học sâu, đề tài hướng đến việc nâng cao hiểu biết về hành vi của mô hình, từ đó góp phần phát triển các hệ thống AI an toàn, minh bạch và có trách nhiệm hơn.

# CHƯƠNG I: TỔNG QUAN ĐỀ TÀI

## 1.1 Giới thiệu

Trong bối cảnh y học hiện đại, việc chẩn đoán hình ảnh đóng vai trò then chốt trong quá trình phát hiện và điều trị nhiều bệnh lý nguy hiểm, trong đó viêm phổi là một trong những nguyên nhân hàng đầu gây tử vong ở nhóm trẻ em, người cao tuổi và những bệnh nhân có cơ địa suy giảm miễn dịch. Ảnh X-quang ngực (Chest X-ray) là phương pháp phổ biến nhất nhờ chi phí thấp và khả năng thực hiện nhanh chóng. Sự kết hợp giữa trí tuệ nhân tạo (AI) và hình ảnh y khoa hứa hẹn mang lại bước tiến lớn trong việc nâng cao độ chính xác chẩn đoán, rút ngắn thời gian đọc kết quả và giảm tải cho hệ thống y tế. Tuy nhiên, thách thức về tính minh bạch trong các mô hình AI sâu vẫn là rào cản lớn, đòi hỏi phải có các phương pháp giải thích mô hình (XAI) để tăng cường niềm tin và khả năng ứng dụng trong thực tế lâm sàng.

## 1.2 Vấn đề nghiên cứu

Mặc dù nhiều nghiên cứu đã chứng tỏ hiệu quả cao của các mô hình học sâu (deep learning) trong việc phát hiện viêm phổi từ ảnh X-quang ngực, phần lớn các công trình này vẫn dừng lại ở mức độ "hộp đen" khi không giải thích được rõ ràng cơ sở quyết định của mô hình. Việc thiếu minh bạch này đặt ra rủi ro trong chẩn đoán y khoa, khi bác sĩ cần hiểu rõ lý do của mỗi dự đoán để đưa ra quyết định điều trị phù hợp. Do đó, nghiên cứu cần tập trung vào việc vừa đảm bảo độ chính xác cao vừa kết hợp các kỹ thuật giải thích mô hình, nhằm cung cấp những minh chứng trực quan cho từng dự đoán.

## 1.3 Lịch sử và quan điểm lựa chọn đề tài

Trong thập kỷ qua, sự phát triển của các bộ dữ liệu lớn như ChestX-ray14, CheXpert và MIMIC-CXR đã tạo nền tảng cho các mô hình AI trong chẩn đoán bệnh phổi. Ban đầu, hầu hết nghiên cứu chỉ tập trung vào tối ưu độ chính xác và giảm thiểu sai số, bỏ qua yếu tố giải thích và khả năng tin cậy của mô hình. Đến khoảng năm 2018–2019, xu hướng Explainable AI (XAI) bắt đầu thu hút sự quan tâm, với những phương pháp như LIME, SHAP và Grad-CAM lần lượt được áp dụng để "mở khóa" quy trình

ra quyết định của mạng nơ-ron sâu. Lựa chọn đề tài này dựa trên nhu cầu cấp thiết về một hệ thống AI song hành giữa hiệu năng và tính minh bạch, từ đó hỗ trợ y bác sĩ trong chẩn đoán viêm phổi một cách tự tin và an toàn.

### 1.4 Tóm tắt hoạt động nghiên cứu

Nghiên cứu được tiến hành qua các bước chính: đầu tiên thu thập và tiền xử lý bộ ảnh X-quang ngực từ nguồn dữ liệu công khai; sau đó thiết kế và huấn luyện mô hình học sâu để phân loại trường hợp viêm phổi và bình thường; bước tiếp theo là vận dụng LIME để giải thích kết quả dự đoán, xác định vùng ảnh trọng yếu góp phần vào quyết định; cuối cùng đánh giá hiệu quả tổng hợp của mô hình qua các chỉ số như độ chính xác, độ đặc hiệu, độ nhạy và mức độ tương thích giữa vùng quan trọng do LIME xác định và vùng tổn thương thực tế trên X-quang.

### 1.5 Mục tiêu nghiên cứu

Mục tiêu của đề tài là xây dựng một hệ thống hỗ trợ chẩn đoán viêm phổi trên ảnh X-quang ngực đạt độ chính xác cao đồng thời cung cấp cơ chế giải thích minh bạch cho mỗi kết quả dự đoán. Cụ thể, nghiên cứu sẽ tối ưu hóa mô hình phân loại để đạt ít nhất 90% độ chính xác trên tập kiểm thử và ứng dụng LIME để tạo bản đồ nhiệt chỉ ra các vùng mô phổi quan trọng, giúp bác sĩ dễ dàng xác thực và tiếp nhận kết quả.

### 1.6 Phạm vi và đóng gói

Đề tài tập trung vào phân tích ảnh X-quang ngực thẳng (PA view), không mở rộng sang các loại hình ảnh khác như CT hay MRI. Khung dữ liệu sử dụng bao gồm các ảnh đã được gán nhãn viêm phổi và bình thường, không xử lý thêm các bệnh lý phổi khác. Hệ thống được đóng gói dưới dạng mã nguồn Python, sử dụng các thư viện phổ biến như TensorFlow/Keras cho mô hình học sâu và LIME cho phần giải thích, cùng hướng dẫn cài đặt và sử dụng chi tiết để dễ dàng tái sử dụng và triển khai.

### 1.7 Ý nghĩa và ứng dụng

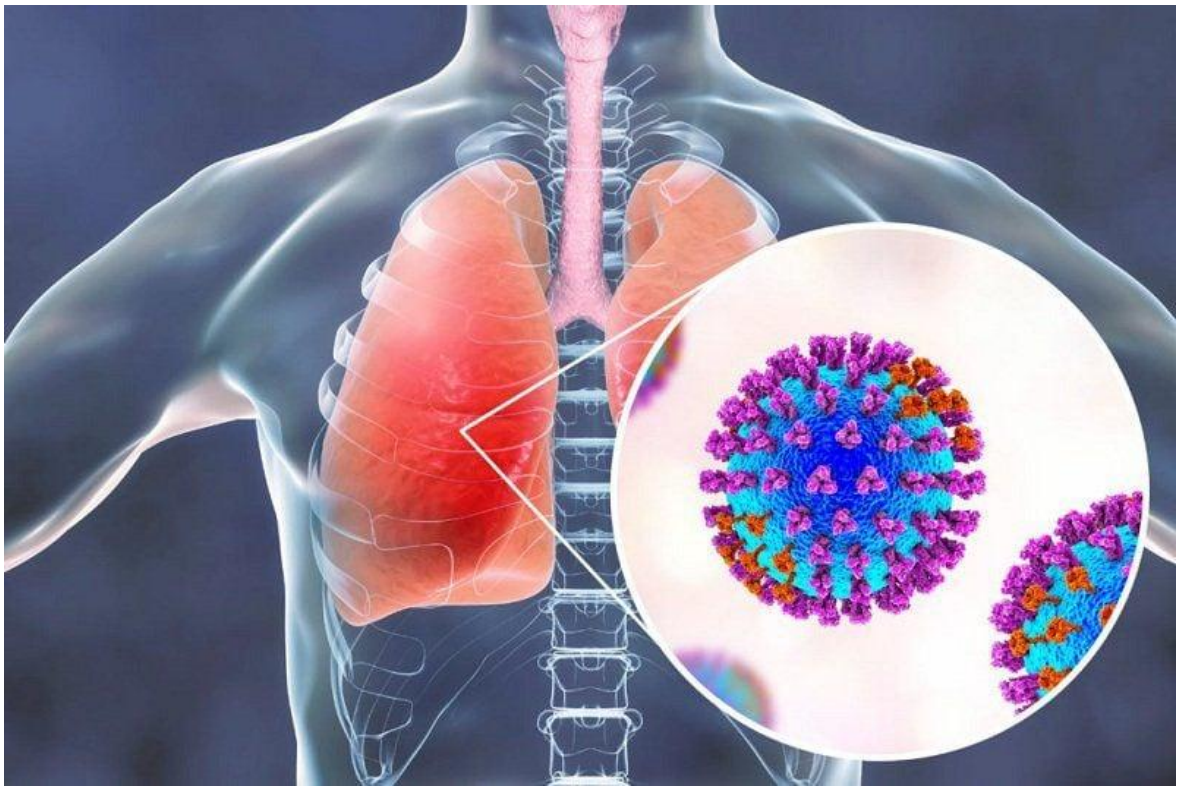
Kết quả nghiên cứu sẽ góp phần nâng cao tính minh bạch và độ tin cậy của hệ thống AI trong chẩn đoán y khoa, cung cấp công cụ minh họa giải thích trực quan cho bác

sĩ khi đọc kết quả phân loại viêm phổi. Về mặt thực tiễn, hệ thống này có thể được triển khai tại các bệnh viện và phòng khám để hỗ trợ chuyên gia chẩn đoán, đặc biệt ở những cơ sở thiếu nhân lực chuyên khoa, góp phần cải thiện chất lượng và hiệu quả điều trị cho bệnh nhân viêm phổi.

# CHƯƠNG II: CƠ SỞ LÝ THUYẾT

## 2.1 Tổng quan về bệnh viêm phổi (Pneumonia)

Viêm phổi là một bệnh lý nhiễm trùng cấp tính tại nhu mô phổi, trong đó các phế nang và mô kẽ bị viêm và chứa đầy dịch hoặc mủ. Bệnh có thể gây ra bởi vi khuẩn, virus, nấm hoặc hít phải dị vật, và là một trong những nguyên nhân hàng đầu gây tử vong do bệnh nhiễm trùng, đặc biệt ở trẻ em, người già và người có bệnh nền.



*Hình 2.1: Hình ảnh viêm phổi (Pneumonia)*

1. Nguyên nhân

- Vi khuẩn: Phổ biến nhất là *Streptococcus pneumoniae, Haemophilus influenzae, Klebsiella pneumoniae*...
- Virus: Cúm, RSV, SARS-CoV-2, adenovirus...
- Nấm: *Pneumocystis jirovecii, Aspergillus spp.*, thường gặp ở người suy giảm miễn dịch.
- Khác: Hít phải chất lạ (dị vật, dịch dạ dày), viêm phổi do bệnh viện.

2. Phân loại lâm sàng

- Viêm phổi cộng đồng (CAP)

- Viêm phổi bệnh viện (HAP)
- Viêm phổi liên quan đến thở máy (VAP)
- Viêm phổi hít (do hít phải dị vật hoặc dịch dạ dày)

3. Triệu chứng lâm sàng

- Sốt, ho có đờm hoặc khan
- Khó thở, thở nhanh
- Đau ngực kiểu màng phổi
- Mệt mỏi, chán ăn, đặc biệt ở người già và trẻ nhỏ

4. Chẩn đoán hình ảnh

- X-quang ngực là công cụ chính để phát hiện viêm phổi. Hình ảnh thường thấy là:
    - Đám mờ phế nang hoặc mô kẽ ở một hoặc nhiều thùy phổi
    - Mờ đồng nhất, có thể kèm theo tràn dịch màng phổi
- Ngoài ra, CT ngực có thể được chỉ định trong các trường hợp phức tạp.

5. Điều trị

- Kháng sinh là điều trị chính cho viêm phổi do vi khuẩn.
- Viêm phổi do virus: thường điều trị hỗ trợ, một số trường hợp dùng thuốc kháng virus.
- Hỗ trợ: thở oxy, hạ sốt, bù dịch.

6. Tầm quan trọng trong AI/XAI

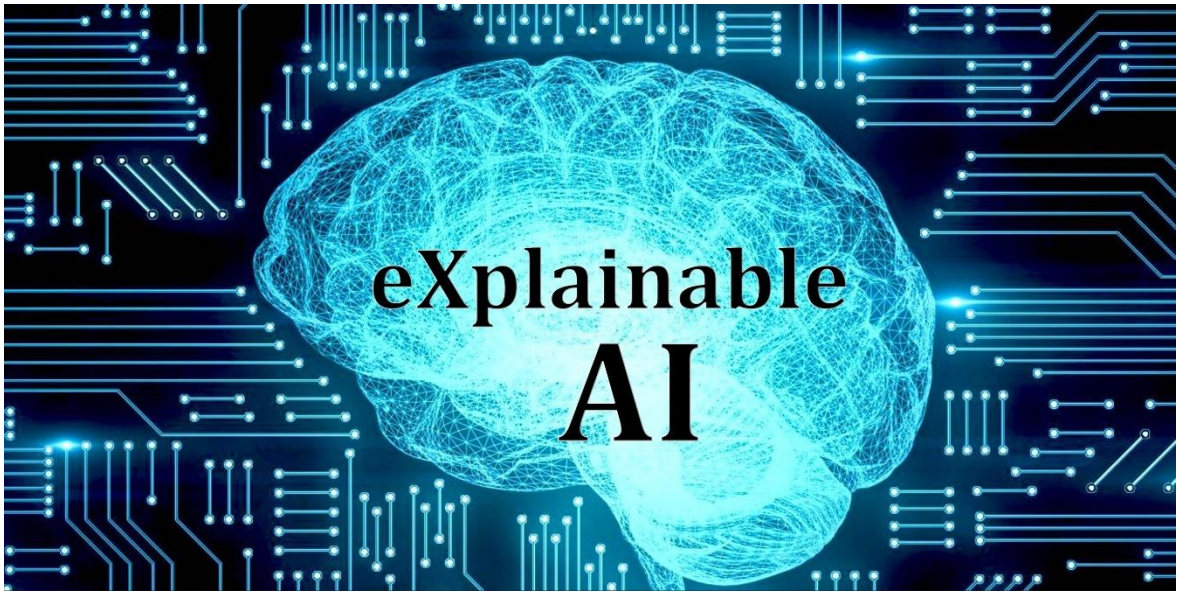
Viêm phổi là một trong những bệnh được nghiên cứu nhiều nhất trong các mô hình học sâu phân tích X-quang ngực. Các bộ dữ liệu phổ biến như ChestX-ray14, CheXpert, MIMIC-CXR đều chứa nhãn viêm phổi, cho phép phát triển mô hình AI phát hiện bệnh này. Giải thích mô hình bằng XAI (ví dụ Grad-CAM, LIME) giúp tăng độ tin cậy, hỗ trợ bác sĩ trong lâm sàng.

## 2.2 Tổng quan về Explainable AI (XAI)

### 2.2.1 Giới thiệu Explainable AI (XAI)

- Explainable AI (XAI) là tập hợp các phương pháp, kỹ thuật và công cụ nhằm "mở hộp đen" (black-box) của các mô hình học sâu (deep learning), giúp con người hiểu được cách thức mà mô hình đưa ra dự đoán hoặc quyết định. Khác với những mô

hình truyền thống chỉ cho kết quả đầu ra (output), XAI cung cấp các thông tin giải thích (interpretation) về những yếu tố nội tại (features, layers, gradients…) đã tác động tới kết quả đó.




*Hình 2.2: Giới thiệu chung về eXplainable AI*

### 2.2.2 Vai trò và lợi ích của XAI

- Tính minh bạch (Transparency)

XAI cho phép người phát triển và người dùng cuối nhìn rõ luồng thông tin bên trong mô hình, từ việc trích xuất đặc trưng (feature extraction) đến việc kết hợp các giá trị trung gian để tạo ra dự đoán cuối cùng. Khi gặp dự đoán không chính xác, XAI giúp tìm ra nguyên nhân (ví dụ: bias do dữ liệu, lỗi trong kiến trúc mạng).

- Tin cậy (Trustworthiness)

Các ứng dụng quan trọng như y tế, tài chính, an ninh đều đòi hỏi mô hình không chỉ chính xác mà còn phải đáng tin cậy. XAI cung cấp các "bằng chứng" (evidence) để người dùng – bác sĩ, kỹ sư, nhà hoạch định chính sách – cảm thấy yên tâm khi tin tưởng vào kết quả mô hình đưa ra.

- Tuân thủ quy định (Regulatory Compliance)

Ở nhiều lĩnh vực, luật pháp và quy định yêu cầu phải giải trình (explainability) về kết quả tự động. Ví dụ, Luật Bảo vệ Dữ liệu Chung của EU (GDPR) quy định

quyền được giải thích khi mô hình AI tác động đến quyền lợi cá nhân. XAI giúp các tổ chức đáp ứng tốt các yêu cầu này.

### 2.2.3 Lịch sử phát triển của XAI

Giai đoạn khởi đầu: Trí tuệ nhân tạo và khả năng giải thích ban đầu (1950s–1980s)

- AI thời kỳ đầu:
  - Các hệ thống AI thời kỳ đầu như Expert Systems (ví dụ: MYCIN, DENDRAL) được thiết kế theo luật "nếu – thì".
  - Những hệ thống này vốn có tính giải thích cao, vì chúng dựa trên luật rõ ràng do con người lập trình thủ công.
  - MYCIN (1970s) có thể giải thích các khuyến nghị y khoa dựa trên logic và chuỗi luật đã sử dụng.

Giai đoạn “hộp đen” của AI: Sự trỗi dậy của học máy (1980s–2000s)

- Mất đi tính giải thích:
  - AI chuyển sang học máy (Machine Learning), đặc biệt là các mô hình như cây quyết định, mạng nơ-ron.
  - Mô hình trở nên khó hiểu hơn, vì quyết định được tạo ra thông qua hàm phức tạp, thay vì luật tường minh.
- Kỷ nguyên Deep Learning và nhu cầu XAI (2010s–nay)
  - Sự phát triển của Deep Learning (CNN, RNN, Transformers) đạt được kết quả ấn tượng trong thị giác máy tính, NLP...
  - Tuy nhiên, các mô hình này là "hộp đen" phức tạp, gây ra mối lo ngại về tính minh bạch, công bằng và đạo đức.
- Sự phát triển của các kỹ thuật XAI (2016–nay)

Các phương pháp chính:

- Post-hoc Explainability (giải thích sau khi huấn luyện):
  - SHAP (SHapley Additive exPlanations)
  - LIME (Local Interpretable Model-agnostic Explanations)
  - Grad-CAM (Class Activation Mapping trong thị giác máy tính)

- Interpretable Models (mô hình dễ hiểu ngay từ đầu):
    - Rule-based learning, cây quyết định, GAMs (Generalized Additive Models)
- XAI cho mô hình ngôn ngữ:
    - Attention visualization (trong Transformers)
    - Rationale extraction

## 2.3 EfficientNetB0

### 2.3.1 Lịch sử phát triển và mục tiêu của EfficientNetB0

#### 2.3.1.1 Lịch sử phát triển

- Tiền thân – MobileNets & NAS
    - Cuối 2017 – 2018: MobileNetV1/V2 (Google) giới thiệu khối MBConv (Mobile Inverted Bottleneck Convolution) và cơ chế depthwise separable convolution, trở thành backbone nhẹ cho thiết bị di động.
    - 2018: MNASNet (Google) là mạng đầu tiên kết hợp Neural Architecture Search (NAS) với tiêu chí cân bằng giữa độ chính xác và độ trễ (latency) thực tế trên thiết bị.
- EfficientNet ra đời
    - Tháng 5/2019: Mingxing Tan & Quoc Le (Google) công bố bài báo
        - "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks"
    - Họ sử dụng NAS để tìm ra kiến trúc cơ sở (base network) – đó chính là EfficientNet-B0 – sau đó đề xuất Compound Scaling để mở rộng lên các phiên bản B1…B7.
- Sau khi xuất bản
    - EfficientNet nhanh chóng trở thành backbone phổ biến cho nhiều bài toán: classification, detection, segmentation, pose estimation…
    - Nhiều thư viện (TensorFlow, PyTorch) tích hợp sẵn, cộng đồng nghiên cứu và sản xuất ứng dụng rộng rãi.

#### 2.3.1.2 Mục tiêu thiết kế của EfficientNetB0

- Tối ưu trade-off giữa độ chính xác (accuracy) và tài nguyên tính toán (FLOPs, parameters)
  - Truyền thống thường tăng depth (sâu) hoặc width (rộng) hoặc độ phân giải ảnh riêng lẻ → không tối ưu.
  - EfficientNet-B0 được tìm ra bằng NAS nhằm đạt độ chính xác cao trên ImageNet trong khi sử dụng rất ít FLOPs và parameter.
- Khởi điểm cho việc mở rộng quy mô (scaling)
  - Birth-point (kiến trúc cơ sở) có thể "compound-scale" đồng thời cả:
    - Depth (số lớp),
    - Width (số channel),
    - Resolution (kích thước ảnh đầu vào)
  - Các hệ số scaling được xác định rõ ràng cho từng phiên bản B1…B7, giúp dễ dàng tùy chỉnh theo yêu cầu tài nguyên/hardware.
- Sử dụng các thành phần đã được chứng minh hiệu quả
  - MBConv + SE: tận dụng building block nhẹ của MobileNetV2 cộng cơ chế Squeeze-and-Excitation để tăng khả năng học đặc trưng.
  - Swish activation: hàm kích hoạt x·σ(x)x \cdot \sigma(x)x·σ(x) cho hiệu năng tốt hơn ReLU.
- Tính tổng quát và chuyển giao (transfer learning)
  - EfficientNet-B0 như một backbone nhẹ nhưng mạnh mẽ, dễ dàng fine-tune cho các task downstream (detection, segmentation, pose estimation) trên nhiều loại thiết bị, từ server tới edge device.

### 2.3.2 Kiến trúc tổng quát của EfficientNetB0

EfficientNet là dòng mô hình CNN do Google AI Brain đề xuất, nổi bật với compound scaling – đồng thời mở rộng chiều sâu (depth), chiều rộng (width) và độ phân giải (resolution) theo tỉ lệ cân bằng. Trong đó:

- EfficientNetB0 là phiên bản cơ sở với ~5 triệu tham số, inference nhanh, dễ fine-tune.

- Sử dụng depthwise separable convolution và module squeeze-and-excitation để giảm số phép tính mà vẫn đảm bảo độ chính xác.

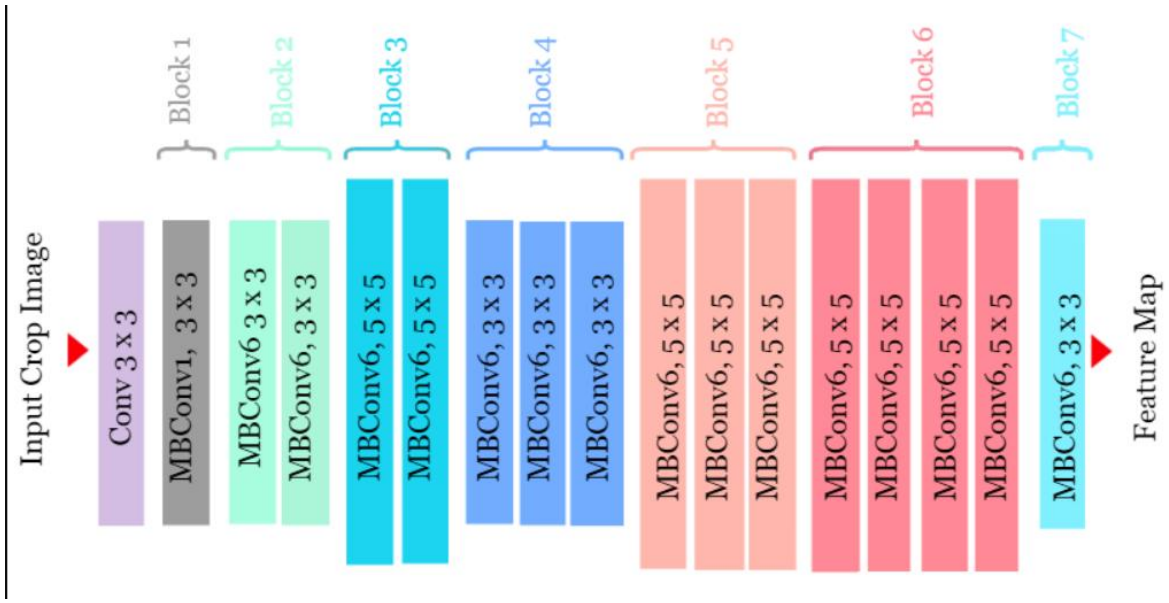
1. Input & Stem
   - Input Crop Image: độ phân giải gốc (mặc định 224×224×3)
   - Conv 3×3 (màu tím)
     – stride=2, tăng số kênh lên 32
     – BatchNorm + Swish
     – Kích thước giảm: 224→112
2. Block 1 (Màu xám) - MBConv1, 3x3
   - Expansion factor t=1 → không mở rộng kênh.
   - Depthwise Conv 3×3, stride=1
   - SE block:
     - GlobalAvgPool → FC giảm kênh 16→4 → Swish → FC tăng → Sigmoid → scale.
   - Projection 1×1 về 16 kênh.
   - Residual: do stride=1 và in/out channels đều 16 nên nối skip-connection.
   - Output: 112×112×16.
3. Block 2 (Màu xanh lá nhạt) - MBConv6, 3x3 x2 lần
   - MBConv6 lần 1:
     - Expansion t=6: 16→96 kênh.
     - Depthwise Conv 3×3, stride=2
     - Output không gian: 112→56, kênh tạm 96.
     - SE + Projection 1×1 → 24 kênh.
     - Không có residual (stride≠1).
     - Output: 56×56×24.
   - MBConv6 lần 2:
     - Expansion t=6: 24→144 kênh.
     - Depthwise Conv 3×3, stride=1 (giữ 56×56).
     - SE + Projection 1×1 → 24 kênh.
     - Residual: vì stride=1 & in/out đều 24.

- Output: 56×56×24.

4. Block 3 (Màu xanh dương nhạt) - MBConv6, 5x5 x2 lần
   - MBConv6 lần 1:
     - Expansion: 24→144 kênh.
     - Depthwise Conv 5×5, stride=2 → không gian 56→28.
     - SE + Projection → 40 kênh.
     - Không residual.
   - MBConv6 lần 2:
     - Expansion: 40→240 kênh.
     - Depthwise Conv 5×5, stride=1 (28x28)
     - SE + Projection → 40 kênh.
     - Residual: do 28×28 và kênh in/out =40.
     - Output: 28×28×40.
5. Block 4 (Màu xanh dương) - MBConv6, 3x3 x3 lần
   - MBConv6 lần 1:
     - t: 40→240, depthwise 3×3, stride=2 → 28→14.
     - SE + proj → 80 kênh.
     - Không residual.
   - MBConv6 lần 2 và lần 3:
     - t: 80→480, depthwise 3×3, stride=1 (giữ 14×14).
     - SE + proj → 80 kênh.
     - Có residual.
     - Output: 14×14×80.
6. Block 5 (Màu cam nhạt) - MBConv6, 5x5 x3 lần
   - MBConv6 3 lần:
     - t: 80→480 → depthwise 5×5, stride=1 (14×14).
     - SE + proj → 112 kênh.
     - Lớp 2 & 3 có residual (vì in/out =112, stride=1).
     - Ouput: 14x14x112
7. Block 6 (Màu hồng đậm) - MBConv6, 5x5 x4 lần

- MBConv6 lần 1:
    - t: 112→672, depthwise 5×5, stride=2 → 14→7.
    - SE + proj → 192 kênh.
    - Không residual.
- MBConv6 lần 2 - lần 4:
    - t: 192→1152, depthwise 5×5, stride=1 (7×7).
    - SE + proj → 192 kênh.
    - Có residual.
    - Output: 7×7×192.

8. Block 7 (Màu xanh ngọc) - MBConv6, 3x3
    - MBConv6:
        - t: 192→1152, depthwise 3×3, stride=1 (7×7).
        - SE + proj → 320 kênh.
        - Có residual.
        - Output: 7x7x320
9. Head (Kết thúc)
    - Conv 1×1 → 1 280 channels + BN + Swish
        - Tăng chiều sâu kênh để thu thập đặc trưng tổng hợp.
        - Output: 7×7×1280.
    - Global Average Pooling
        - Chuyển 7×7×1280 → vector 1 280-D.
    - Dropout p=0.2
        - Giảm overfitting.
    - Fully-Connected → 1 000 classes
        - Dành cho classification ImageNet, theo sau là Softmax.




*Hình 2.3: EfficientNetB0 Architecture*

### 2.3.3 Ưu điểm và nhược điểm của EfficientNetB0

Ưu điểm:

- Hiệu năng trên FLOPs tối ưu
  - Cho độ chính xác Top-1 ~77.1% trên ImageNet chỉ với ~390M FLOPs và ~5.3M tham số.
  - So với các kiến trúc tương đương (ResNet-50, Inception-V3…), thường đạt độ chính xác tương đương/sâu hơn nhưng tốn ít tài nguyên hơn.
- Compound Scaling linh hoạt
  - Thiết kế B0 dễ dàng "scale up" đồng thời về chiều sâu, chiều rộng và độ phân giải để ra các phiên bản B1–B7 theo nhu cầu phần cứng và độ chính xác.
- Backbone nhẹ, dễ chuyển giao
  - Phần "backbone" (đến Block 7 hoặc đến Conv1×1 "expansion head") rất thích hợp để fine-tune cho các bài toán downstream (detection, segmentation, pose estimation…) trên cả server lẫn edge.

- Cơ chế MBConv + SE + Swish
  - MBConv (inverted bottleneck + depthwise) giảm đáng kể tính toán so với conv thông thường.
  - SE (Squeeze-and-Excitation) tăng khả năng học đại diện qua cân kênh.
  - Swish activation cải thiện hiệu năng so với ReLU.
- Ứng dụng thực tế sẵn sàng
  - Được hỗ trợ trong TensorFlow, PyTorch, ONNX, TFLite, dễ triển khai trên di động/edge.

Nhược điểm:

- Kiến trúc "cứng" với NAS kết quả
  - B0 là kết quả tìm kiến trúc tự động; nếu phần cứng hay dữ liệu của bạn khác biệt lớn, có thể không phải là thiết kế tối ưu nhất.
- Swish tốn bộ nhớ
  - Swish cần lưu thêm giá trị sigmoid(x) trong backward pass, tốn RAM hơn ReLU.
- Độ phức tạp cấu trúc
  - Nhiều tham số (t, kernel size, số layer) khác nhau cho mỗi block, gây khó khăn khi tự triển khai thủ công hoặc debug.
- Không "nhỏ" nhất có thể
  - Với các ứng dụng cực "nhẹ" (microcontroller, IoT cực hạn), vẫn có các kiến trúc như MobileNetV2/V3, TinyML hay model NAS chuyên cho edge còn gọn hơn.
- Yêu cầu tuning khi fine-tune
  - Để đạt hiệu quả tối ưu trên task downstream, thường cần điều chỉnh learning rate, số class, dropout,… khá kỹ lưỡng.

# CHƯƠNG III: CÁC PHƯƠNG PHÁP ĐỀ XUẤT

## 3.1 Môi trường cài đặt

**Google Colab**

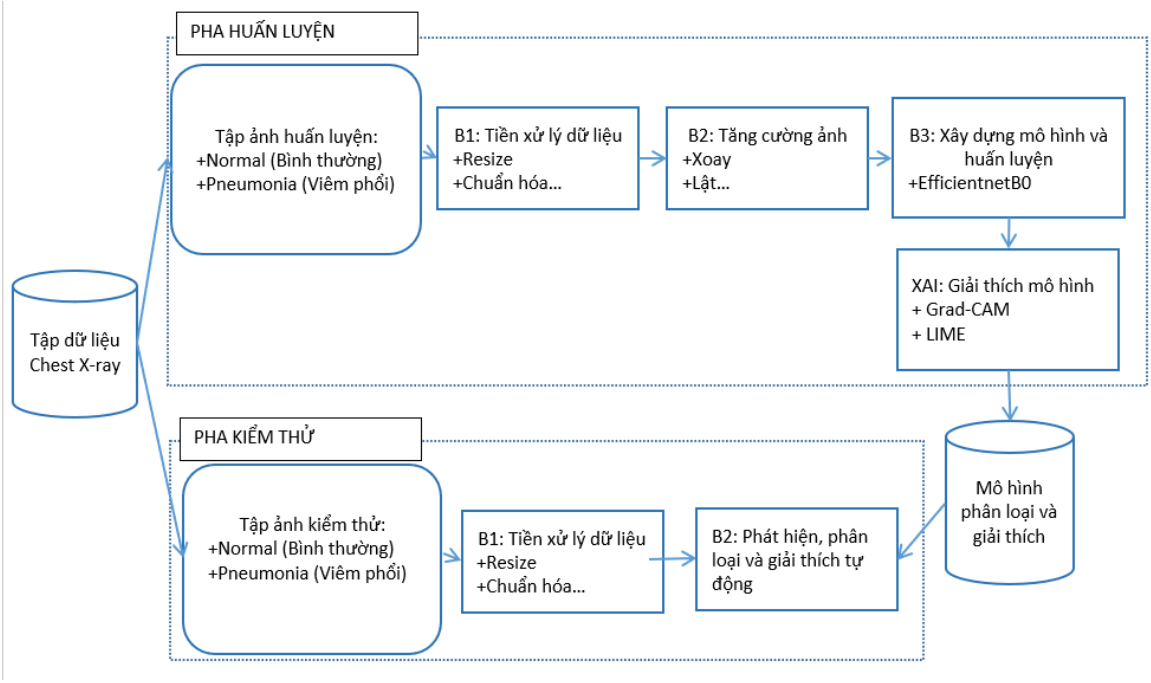



*Hình 3.1: Môi trường Google Colab*

Google Colab là một nền tảng miễn phí do Google phát triển, cho phép người dùng chạy mã Python trực tiếp trên nền tảng đám mây mà không cần cài đặt phần mềm cục bộ. Google Colab hỗ trợ mạnh mẽ cho các ứng dụng học máy và học sâu nhờ khả năng:

- Cung cấp GPU/TPU miễn phí (như Tesla T4, K80, P100…)
- Hỗ trợ thư viện học sâu phổ biến như TensorFlow, PyTorch, Keras, OpenCV, Scikit-learn, v.v.
- Tích hợp Google Drive giúp lưu trữ dữ liệu và mô hình thuận tiện.

### 3.2 Mô hình đề xuất




*Hình 3.2: Mô hình đề xuất*

1. Pha huấn luyện

- Tập ảnh huấn luyện: Bao gồm hai nhóm chính:
    - Ảnh X-quang phổi bình thường (*Normal*)
    - Ảnh X-quang phổi bị viêm (*Pneumonia*)
- Bước 1 – Tiền xử lý dữ liệu: Các ảnh được chuẩn hóa về kích thước (resize), chuyển đổi kênh màu, chuẩn hóa cường độ pixel, v.v.
- Bước 2 – Tăng cường dữ liệu: Nhằm tăng tính đa dạng và khả năng tổng quát của mô hình, ảnh được xoay, lật ngang/dọc, hoặc áp dụng các kỹ thuật biến đổi ảnh khác.
- Bước 3 – Huấn luyện mô hình:
    - Mô hình EfficientNetB0 được lựa chọn để học đặc trưng và phân loại.
    - Sau quá trình huấn luyện, mô hình có khả năng phân biệt giữa ảnh phổi bình thường và ảnh viêm phổi.

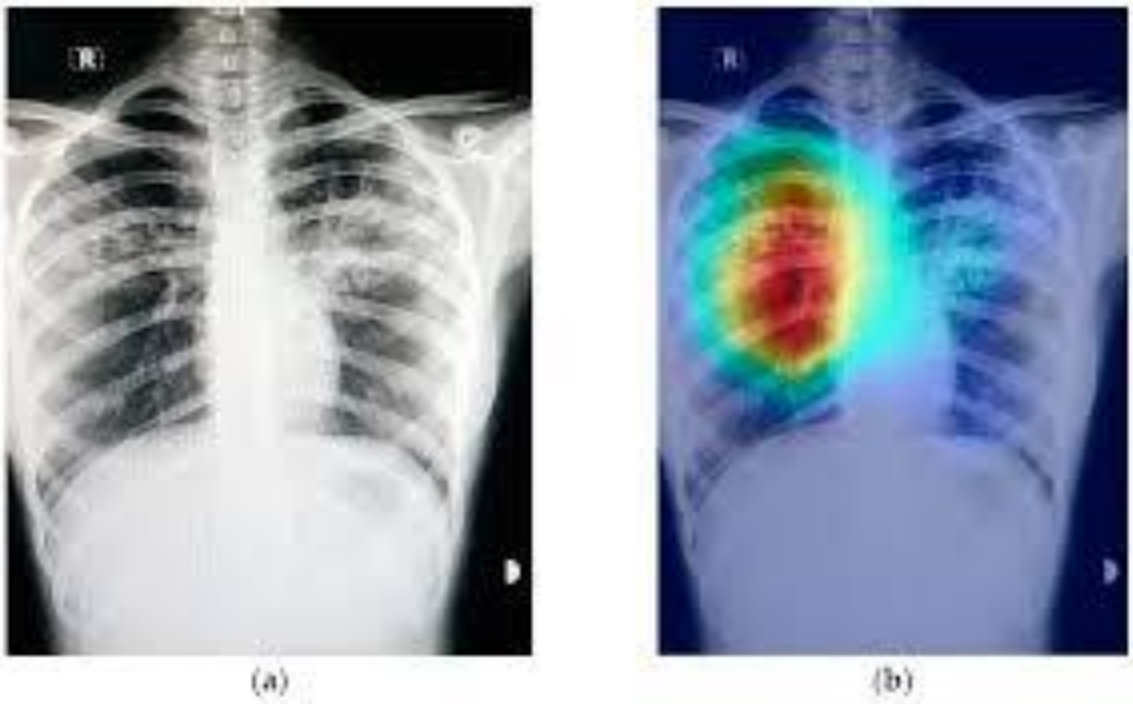
- XAI – Giải thích mô hình:
    - Các phương pháp Grad-CAM (sử dụng gradient lớp convolution cuối) và LIME (mô hình cục bộ bất khả tri) được áp dụng để tạo bản đồ nhiệt (heatmap) giải thích quyết định của mô hình.

2. Pha kiểm thử

- Tập ảnh kiểm thử: Cũng bao gồm hai loại ảnh tương tự tập huấn luyện (Normal và Pneumonia), nhưng không trùng lặp, dùng để đánh giá mô hình.
- Bước 1 – Tiền xử lý: Tương tự như pha huấn luyện.
- Bước 2 – Phân loại và giải thích tự động:
    - Mô hình đã huấn luyện được dùng để dự đoán phân loại ảnh mới.
    - Đồng thời, Grad-CAM và LIME cũng được áp dụng để giải thích kết quả phân loại – từ đó giúp bác sĩ hoặc người dùng hiểu được lý do đằng sau quyết định của mô hình.

### 3.3 Grad-Cam (Gradient-weighted Class Activation Mapping)

Grad-CAM (Gradient-weighted Class Activation Mapping) là một kỹ thuật phổ biến trong lĩnh vực thị giác máy tính (computer vision), đặc biệt để giải thích và trực quan hóa cách mạng nơ-ron tích chập (CNN) đưa ra quyết định phân loại hình ảnh




*Hình 3.3: Ảnh ví dụ Grad-CAM*

### 3.3.1 Lịch sử ra đời và mục tiêu

#### 3.3.1.1 Lịch sử ra đời

1. Class Activation Mapping (CAM) – 2016

- Tác giả: Bolei Zhou et al.
- Bài báo: "Learning Deep Features for Discriminative Localization"
- CAM là kỹ thuật đầu tiên cho phép trực quan hóa những vùng nào trong ảnh ảnh hưởng nhiều nhất đến quyết định phân loại.
- Hạn chế: Chỉ áp dụng được cho những mạng CNN đặc biệt có kiến trúc "global average pooling" ngay trước lớp fully connected (FC), không áp dụng được cho mạng như VGG hay ResNet.

1. Grad-CAM – 2017

- Tác giả: Ramprasaath R. Selvaraju et al.
- Bài báo: "Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization"
- Grad-CAM mở rộng CAM bằng cách sử dụng gradient để tính tầm quan trọng của từng feature map trong mạng CNN.

- Ưu điểm: Áp dụng được với nhiều mô hình CNN khác nhau như VGG, ResNet, Inception, v.v.
- Cơ chế chính: Dựa vào gradient của lớp đầu ra (output) với từng feature map của lớp convolution cuối cùng

2. Grad-CAM++ – 2018
   - Tác giả: Aditya Chattopadhay et al.
   - Bài báo: "Grad-CAM++: Generalized Gradient-Based Visual Explanations for Deep Convolutional Networks"
   - Cải thiện Grad-CAM bằng cách cân nhắc gradient bậc hai, giúp cải thiện độ chính xác trong việc trực quan hóa ảnh, đặc biệt khi có nhiều đối tượng hoặc khi ảnh phức tạp.

#### 3.3.1.2 Mục tiêu

Grad-CAM (Gradient-weighted Class Activation Mapping) là một phương pháp trực quan hóa và giải thích quyết định của các mạng nơ-ron tích chập (CNN) trong các bài toán phân loại hình ảnh. Các mục tiêu chính của Grad-CAM bao gồm:

1. Giải thích mô hình (Model Interpretability)

- Grad-CAM giúp hiểu rõ hơn về cách mô hình học sâu đưa ra quyết định bằng cách làm nổi bật các vùng trong ảnh đầu vào có ảnh hưởng lớn đến kết quả phân loại. Điều này đặc biệt quan trọng trong việc phát triển các mô hình AI đáng tin cậy.

2. Trực quan hóa vùng quan trọng (Visualizing Important Regions)

- Phương pháp này tạo ra một bản đồ nhiệt (heatmap) thể hiện các vùng mà mô hình chú ý tới khi dự đoán. Điều này cung cấp một cái nhìn trực quan về cách mạng nơ-ron hoạt động.

3. Kiểm tra và đánh giá mô hình (Debugging and Validation)

- Grad-CAM hỗ trợ việc xác minh liệu mô hình có học đúng các đặc trưng liên quan đến đối tượng cần nhận diện hay không, từ đó giúp phát hiện những trường hợp học lệch hoặc học sai (ví dụ: học dựa vào nền ảnh hoặc watermark).

4. Tăng độ minh bạch và độ tin cậy (Transparency and Trust)

- Việc cung cấp lời giải thích cho dự đoán của mô hình giúp tăng độ tin cậy, nhất là trong các lĩnh vực đòi hỏi sự minh bạch như y tế, tài chính và pháp lý.

5. Hỗ trợ cải thiện mô hình (Model Improvement)

- Thông qua việc quan sát các bản đồ nhiệt từ Grad-CAM, các nhà phát triển có thể đánh giá, điều chỉnh mô hình hoặc dữ liệu huấn luyện nhằm cải thiện hiệu suất và độ chính xác của mô hình.

### 3.3.2 Nguyên lý hoạt động

- Trích xuất feature map từ lớp convolution cuối cùng (vì lớp này vẫn giữ được thông tin không gian - spatial).

- Tính đạo hàm (gradient) của xác suất lớp mục tiêu (ví dụ: "ung thư") đối với từng feature map.

- Tính trung bình gradient theo không gian

- Tổng hợp lại bản đồ kích hoạt có trọng số

- Resize heatmap này để khớp với ảnh gốc và hiển thị.

### 3.3.3 Ưu điểm và nhược điểm

Ưu điểm:

- Nhanh, chỉ cần một forward & backward pass.
- Dễ trực quan với bản đồ nhiệt.
- Áp dụng với hầu hết CNN, không cần thay đổi kiến trúc.

Nhược điểm:

- Độ phân giải thấp do lấy từ layer sâu.
- Không chi tiết tới từng pixel.
- Có thể không ổn định với ảnh nhiễu nhẹ.

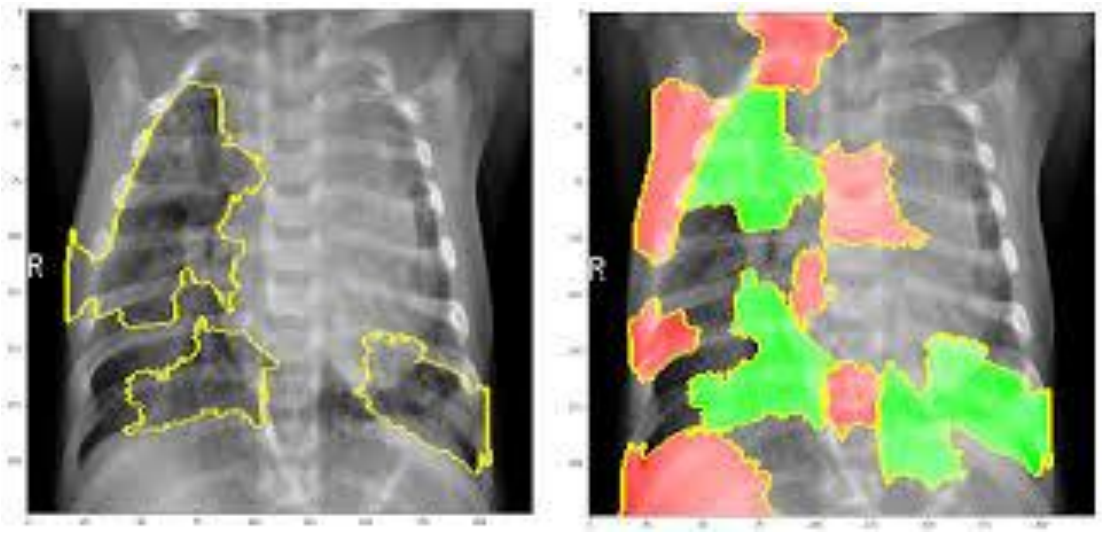
### 3.3.4 Ứng dụng trong ảnh y tế:

- Xác định vùng tổn thương phổi trên X-quang (chẩn đoán COVID, viêm phổi)

- Tìm khối u trong MRI não hoặc tuyến vú
- Hỗ trợ bác sĩ xác nhận mô hình có chú ý đúng vùng bệnh lý

### 3.4 LIME (Local Interpretable Model-agnostic Explanations)

LIME giải thích dự đoán của một mô hình bất kỳ tại một mẫu cụ thể, bằng cách xây dựng một mô hình tuyến tính đơn giản gần điểm đó.




*Hình 3.4: Ảnh ví dụ LIME*

#### 3.4.1 Lịch sử phát triển và mục tiêu

##### 3.4.1.1 Lịch sử phát triển

LIME (Local Interpretable Model-agnostic Explanations) là một phương pháp được phát triển để giải thích dự đoán của các mô hình học máy phức tạp theo cách độc lập với mô hình.

• Tác giả: Marco Tulio Ribeiro, Sameer Singh và Carlos Guestrin

• Bài báo công bố: "Why Should I Trust You? Explaining the Predictions of Any Classifier", năm 2016

• Mục tiêu ban đầu: Giải thích các mô hình học máy như Random Forests, SVM, XGBoost, và đặc biệt là các mô hình học sâu (deep learning) vốn được xem là "hộp đen" (black-box) khó hiểu.

Phương pháp LIME hoạt động theo nguyên lý:

Thay vì giải thích toàn bộ mô hình (global explanation), LIME tập trung vào việc giải thích cục bộ (local explanation) — nghĩa là tại từng điểm dự đoán cụ thể

#### 3.4.1.2 Mục tiêu

LIME được phát triển với nhiều mục tiêu quan trọng, cụ thể như sau:

a. Giải thích cục bộ cho dự đoán (Local Interpretability)

LIME cung cấp lời giải thích cho từng dự đoán riêng lẻ bằng cách tạo ra các mô hình đơn giản (như hồi quy tuyến tính) xung quanh điểm dữ liệu đó. Điều này giúp người dùng hiểu tại sao mô hình lại dự đoán như vậy với một đầu vào cụ thể.

b. Mô hình bất khả tri (Model-agnostic)

Một điểm mạnh lớn của LIME là có thể áp dụng với bất kỳ mô hình nào, từ mạng nơ-ron, cây quyết định, đến SVM hay mô hình ensemble. LIME không phụ thuộc vào cấu trúc nội tại của mô hình gốc.

c. Tăng độ minh bạch và độ tin cậy (Transparency & Trust)

Trong các ứng dụng quan trọng như y tế, tài chính hay pháp luật, LIME giúp con người hiểu và tin tưởng hơn vào các quyết định của AI, đặc biệt là khi kết quả đầu ra ảnh hưởng đến cuộc sống hoặc tài sản của người dùng.

d. Phát hiện và sửa lỗi mô hình (Debugging & Bias Detection)

LIME giúp phát hiện các trường hợp mô hình học sai, học thiên lệch (bias) hoặc phụ thuộc vào những đặc trưng không mong muốn. Điều này hỗ trợ cải thiện chất lượng mô hình và dữ liệu huấn luyện.

### 3.4.2 Nguyên lý hoạt động

- Chia ảnh đầu vào thành các superpixel (nhóm các pixel gần giống nhau).

- Tạo các phiên bản perturbation bằng cách bật/tắt một số superpixel (gán màu xám hoặc làm mờ).

- Dự đoán lại với model gốc → thu tập đầu ra của mô hình cho các biến thể này.

- Tạo mô hình tuyến tính đơn giản (linear model) gán trọng số cho từng superpixel → mô hình này mô phỏng hành vi của model gốc xung quanh mẫu.

- Hiển thị các vùng (superpixel) có trọng số lớn nhất – tức là có ảnh hưởng lớn nhất đến quyết định phân loại.

### 3.4.3 Ưu điểm và nhược điểm của LIME

Ưu điểm:

- Model-agnostic: dùng được với bất kỳ mô hình nào, kể cả "hộp đen".
- Giải thích theo các vùng có ý nghĩa rõ ràng (superpixel).
- Giúp người dùng hiểu được ảnh hưởng của từng vùng ảnh.

Nhược điểm:

- Chạy chậm, vì phải tạo và dự đoán lại hàng trăm lần.
- Kết quả phụ thuộc cách chia superpixel.
- Có thể không ổn định với ảnh phức tạp.

### 3.4.4 Ứng dụng trong ảnh y tế

- Phân tích tại sao ảnh da được phân loại là u ác tính (melanoma).
- Làm rõ vùng nào trên MRI não dẫn tới phân loại là u glioma.
- Tăng độ tin cậy trong chẩn đoán tự động khi cần đối chiếu vùng quyết định.

| Tiêu chí | LIME | GRAD-CAM |
|---|---|---|
| Loại mô hình hỗ trợ | Mọi mô hình (model-agnostic) | Mô hình CNN (model-specific, thường là classification) |
| Kiểu giải thích | Cục bộ (local), mô hình đơn giản gần điểm dữ liệu | Cục bộ (local), dựa trên feature map và gradient |
| Phạm vi ứng dụng | Văn bản, hình ảnh, dữ liệu bảng (text, image, tabular) | Chủ yếu cho ảnh (image classification với CNN) |
| Phương pháp | Sinh dữ liệu nhiễu, gán nhãn mô hình gốc, huấn luyện mô hình đơn giản để giải thích | Sử dụng gradient để làm nổi bật các vùng ảnh ảnh hưởng đến dự đoán |
| Tính minh bạch | Cao, dễ hiểu (giải thích bằng mô hình tuyến tính hoặc cây quyết định) | Trực quan, thông qua bản đồ nhiệt |

*Hình 3.5: Bảng so sánh GRAD-CAM VÀ LIME*

| Tiêu chí | LIME | GRAD-CAM |
|---|---|---|
| Khả năng mở rộng mô hình | Tốt, do không phụ thuộc vào cấu trúc nội tại | Hạn chế cho các mô hình phi hình ảnh |
| Tính trực quan | Trung bình đến cao (tuỳ theo loại dữ liệu) | Rất cao (trực tiếp thấy vùng ảnh được chú ý) |
| Tính toán | Tốn thời gian hơn do cần sinh nhiều mẫu | Tính toán nhanh hơn, dùng ngay gradient từ mô hình |

*Hình 3.6: Bảng so sánh GRAD-CAM VÀ LIME*

# CHƯƠNG IV : KẾT QUẢ THỰC NGHIỆM

## 4.1 Mô tả tập dữ liệu:

Tập dữ liệu bao gồm 5800 ảnh và trước khi huấn luyện mô hình được chia theo tỉ lệ 80:20.

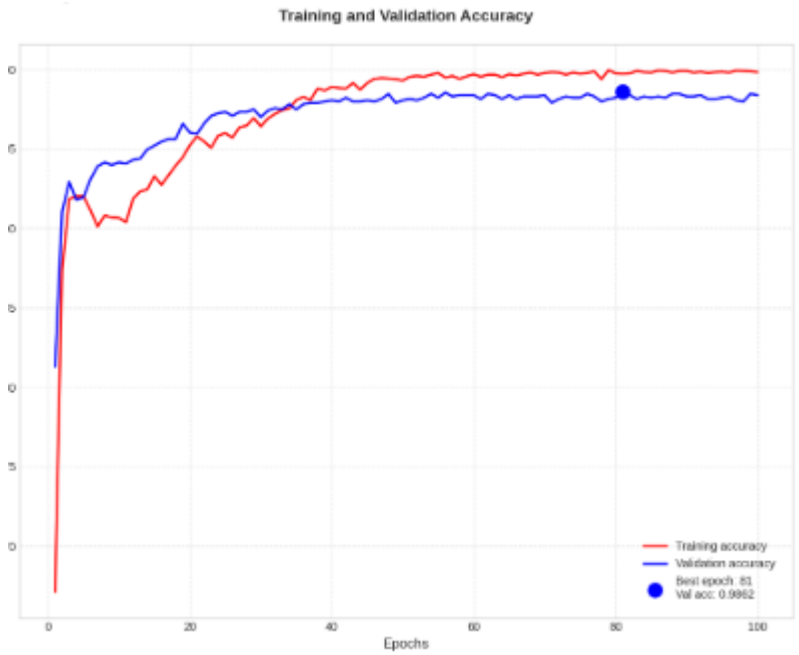
| Tên lớp | Số lượng | Loại |
|---|---|---|
| Normal(Tệp train) | 1341 ảnh | Ảnh X-ray |
| Pneumonia(Tệp train) | 3875 ảnh | Ảnh X-ray |

## 4.2 Môi trường cài đặt:

Hệ thống được cài đặt bằng ngôn ngữ Python và chạy trên môi trường google colab

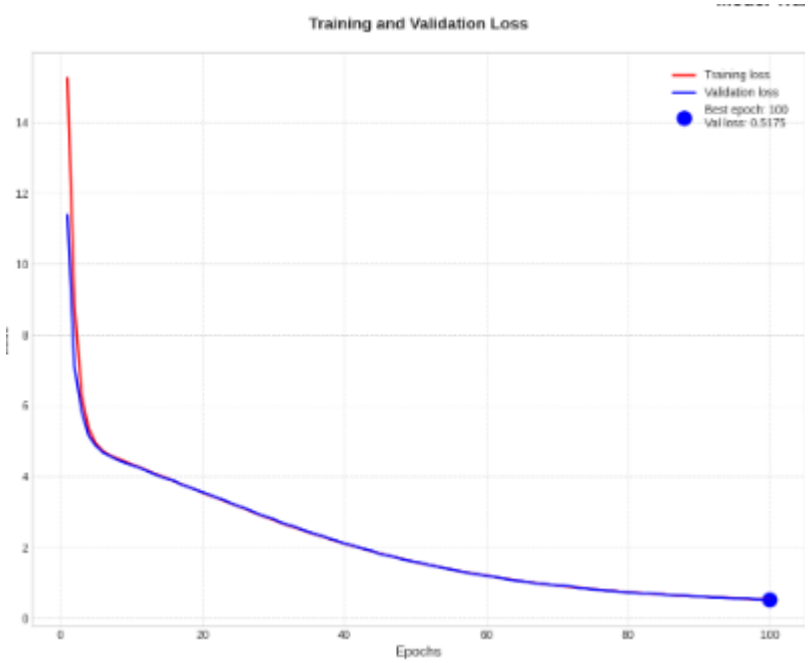
## 4.3 Kết quả huấn luyện

### 4.3.1 Biểu đồ Accuracy




*Hình 4.3.1: Biểu đồ Accuracy của mô hình EfficientNetB0*

### 4.3.2 Biểu đồ  Loss



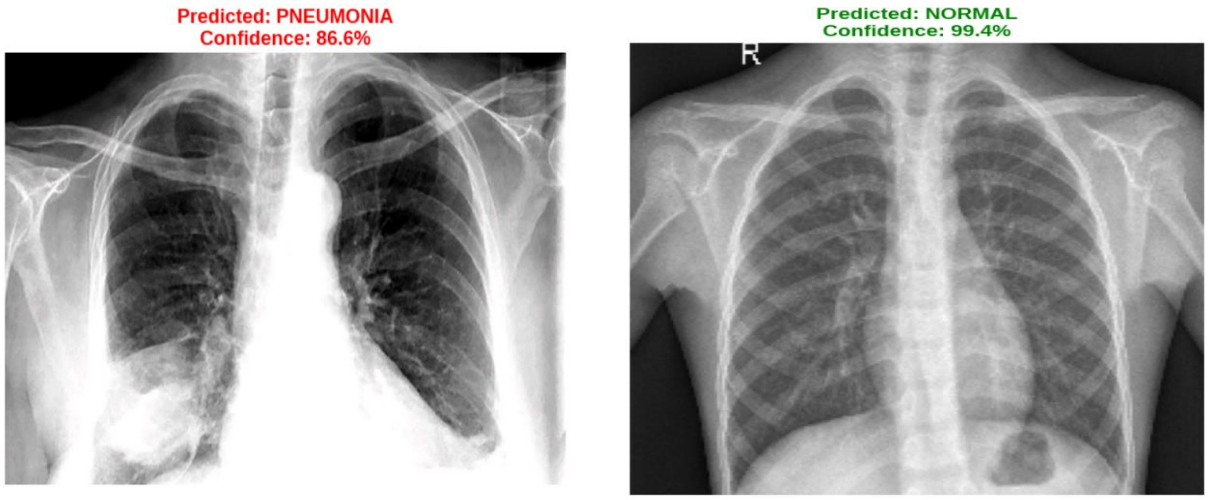

*Hình 4.3.2: Biểu đồ Loss của mô hình EfficientNetB0*

### 4.3.3 Thời gian huấn luyện

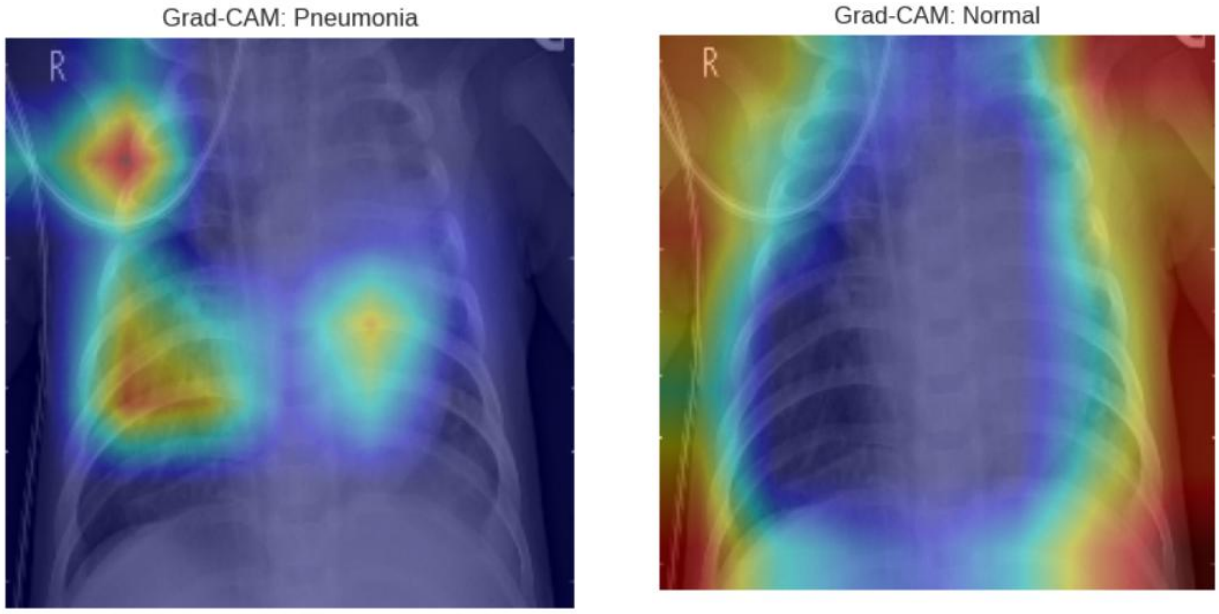
*Bảng 4.2 Thời gian huấn luyện*

| Mô hình | Thời gian | Số epoch |
|---|---|---|
| EfficientNetB0 | 195 phút | 100 |

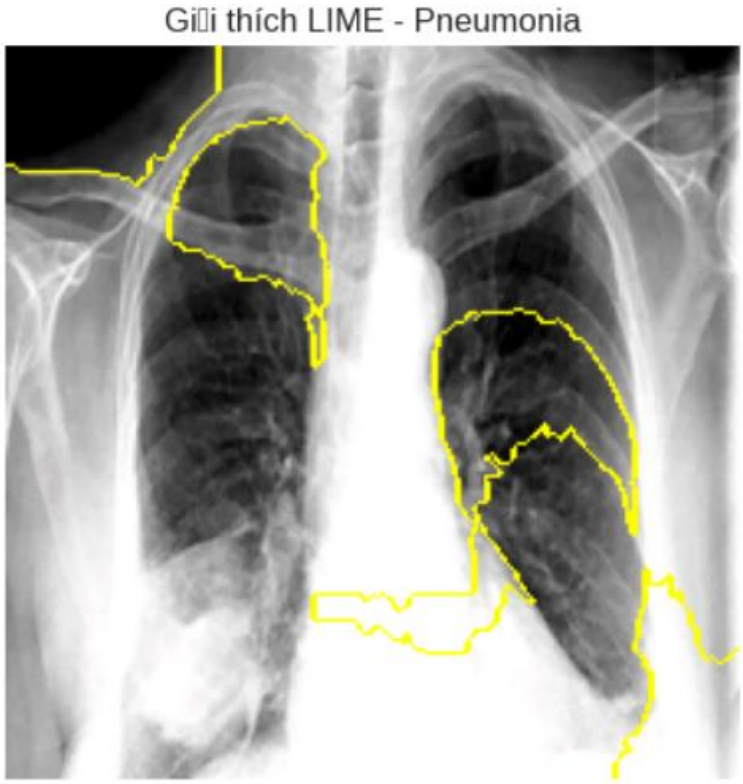
## 4.4 Kết quả kiểm thử




*Hình 4.4.1: Ảnh kết quả chẩn đoán sử dụng mô hình EfficientNetB0*




*Hình 4.4.2: Grad-CAM trên ảnh Pneumonia – vùng viêm phổi sáng rõ.*




*Hình 4.4.3: LIME – superpixel quan trọng làm nổi bật rời rạc.*

## 4.5 Đánh giá kết quả

Độ rõ nét (Clarity)

- Grad-CAM: Vùng chung rõ ràng, bác sĩ nhanh chóng nhận diện khu vực.
- LIME: Superpixel rời rạc, đôi lúc cắt ngang vùng tổn thương.

Hiệu năng tính toán

- Grad-CAM: ~10s/1 ảnh
- LIME: ~100s/1 ảnh

# CHƯƠNG V : KẾT LUẬN VÀ HƯỚNG NGHIÊN CỨU

## 5.1 Kết luận

- Grad-CAM: phù hợp với các ứng dụng đòi hỏi tốc độ và trực quan ngay.
- LIME: ít phù hợp với dữ liệu y tế do rời rạc.

## 5.2 Thách thức

- Ảnh y tế thường độ phân giải cao, chứa nhiều chi tiết nhỏ.

- Mô hình multi-label hoặc multi-output (như ChestX-ray14) phức tạp hơn do cần giải thích đồng thời nhiều nhãn.

## 5.3 Hướng phát triển

- XAI đa độ phân giải (multi-scale XAI): Kết hợp Grad-CAM ở nhiều lớp để nhận diện tổn thương kích thước khác nhau.

- Human-in-the-loop: Cho phép bác sĩ phản hồi heatmap/attribution để fine-tune lại mô hình.

- Giải thích 3D: Mở rộng từ X-ray sang CT/MRI, tích hợp giải thích theo không gian (3D) và thời gian (4D).

# TÀI LIỆU THAM KHẢO


DATASET

Mooney, P. T. (2018). *Chest X-ray Pneumonia* [Data set]. Kaggle. https://www.kaggle.com/datasets/paultimothymooney/chest-xray-pneumonia Kaggle

**Tiếng Việt**

1. Trung, T.Đ. (2020). *EfficientNet: Model Scaling - Viblo*. [online] Viblo. Available at: https://viblo.asia/p/efficientnet-cach-tiep-can-moi-ve-model-scaling-cho-convolutional-neural-networks-Qbq5QQzm5D8.
2. Mai, N. (2022). *Explainable AI - Bạn có hiểu model của bạn không?* [online] Viblo. Available at: https://viblo.asia/p/explainable-ai-ban-co-hieu-model-cua-ban-khong-m68Z0JdQ5kG [Accessed 21 May 2025].

**Tiếng Anh**

1. Mahasin, M., & Dewi, I. A. (2022). *Comparison of CSPDarkNet53, CSPResNeXt-50, and EfficientNet-B0 Backbones on YOLO v4 as Object Detector*. *International Journal of Engineering, Science and Information Technology*, *2*, 64–72. https://doi.org/10.52088/ijesty.v2i3.291 SCIRP
2. Lopes, T. R. S., Roberto, G. F., Soares, C., Tosta, T. A. A., Silva, A. B., Loyola, A. M., Cardoso, S. V., de Faria, P. R., do Nascimento, M. Z., & Neves, L. A. (2024). Association of Grad-CAM, LIME and Multidimensional Fractal Techniques for the Classification of H&E Images. In *Proceedings of the 19th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications (VISIGRAPP 2024) – Volume 2: VISAPP* (pp. 441–447). Science and Technology Publications. https://doi.org/10.5220/0012358200003660 SciTePress
3. Tan, M. and Le, Q. (2020). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. [online] Available at: https://arxiv.org/pdf/1905.11946.